

计算系统生物学总结：

考试题型：单选 20 题每题 1 分，多选 10 题每题 2 分，名词解释 6 题每题 4 分，简答题 4 题每题 5 分，论述题 1 道题 16 分。

考试信息：

单选很常规，多选基本上都是选 3 个及以上。单选看一下重要的网络拓扑指标，没考具体的计算。名词解释看一下模块度、hub 基因，基本都有话可说。简答题考了极限子的概念以及生物学体现（细胞周期），FBA 流量分析的内容以及优缺点，网络传播算法如随机游走算法的原理，还有基因共表达网络构建的步骤。论述题就是给你一个癌症和正常的 RNA-seq 数据，叫你使用学过的方法来设计流程来挖掘关键靶点。简单就是差异表达分析+WGCNA+机器学习初步筛选靶点，最后构建 PPI 网络，分析网络拓扑特征，网络模块识别（MCODE、MCL），最后进行功能注释（富集分析）。最后的最后可以加入药靶数据库搜索以及湿实验验证。

第一章 系统生物学概述

系统生物学的概念（掌握）：


系统生物学是研究一个生物系统中所有组成成分的构成，以及在特定条件下这些组分之间的相互作用关系的学科。它是在分子生物学基础上发展起来的，它以整合为特征，综合了系统分析、高通量平台、计算机模拟、数据整合与信息挖掘等领域的知识，来获取生物系统的结构与功能属性，在系统层次上理解生物。（系统+组成成分+相互作用）

计算系统生物学：更侧重于“系统建模与理解”。它利用生物信息学提供的数据，通过数学建模和计算机模拟来理解生物系统作为一个整体是如何运作的。


第二章 生物学网络基础理论

这几个网络的分类？


- (A) 无向网络
- (B) 有向网络
- (C) 加权网络
- (D) 二分网络




A



B



C



D


在连接两个节点的所有路径中，长度最短的路径称为最短路径，最短路径的长度称为从起点到终点的距离。注意距离是最短的路径

网络中节点G到节点C的路径有哪些？

它们的长度分别为多少？

节点G到节点C的距离是多少？

- $I_1 = \{G, A, B, C\}$
- $I_2 = \{G, A, D, C\}$
- $I_3 = \{G, F, A, B, C\}$
- $I_4 = \{G, F, A, D, C\}$




从节点G到节点C的路径中， I_1 和 I_2 的长度为3， I_3 和 I_4 的长度为4
所以节点G到节点C的距离：3

节点的度 degree

平均连通度 = $2L/N$ 握手定理：总度 = $2L$

用于衡量整个网络的连通性，对于由N个节点，L条边的网络，平均连通度为 $2L/N$



平均连通度是多少？

$$P(k) = N_k / N$$

N_k : 度为 k 的节点数量。

N : 网络中总节点数量。


度分布是描述网络整体结构特征的最重要指标之一。

它告诉我们，网络中“受欢迎”的节点（高连接度）和“普通”节点（低连接度）是如何分布的。

度分布


泊松分布 (Poisson Distribution):

- 大部分节点的度集中在平均度 $\langle k \rangle$ 附近。
- 度远大于平均度的节点极少。
- 对应随机网络 (Random Network)。



幂律分布 (Power-law Distribution):

- $P(k) \sim k^{-\gamma}$ ，其中 γ 通常在2到3之间。
- 绝大多数节点的度很低，但存在少数度极高的“中心节点” (Hubs)。
- 对应无标度网络 (Scale-Free Network)。



大多数生物网络都是无标度的，对应幂律分布。

平均路径长度

网络中任意两个节点之间的最短路径长度的平均值。

$$L = \frac{1}{N(N-1)} \sum_{i \neq j} d(i, j)$$

$d(i, j)$ 是节点 i 和 j 之间的最短路径长度。
 N 是节点总数。

衡量网络的紧凑程度。L 越小，信息或物质在网络中传播得越快。

直径：指网络中任意两个连通节点间距离的最大值。

网络直径代表网络节点连接可能出现的最远距离，标志着网络的紧密程度。


聚类系数

是用来衡量网络中三角关系数量的指标

如果节点 v_1 连接于节点 v_2 ，节点 v_2 连接于节点 v_3 ，那么节点 v_3 很可能与 v_1 相连接。
这种现象被称为三角关系，它体现了部分节点间存在的密集连接性

对于无向网络，节点 v 的聚类系数定义为：

$$CC_v = \frac{n}{C_k^2} = \frac{2n}{k(k-1)}$$



其中 n 表示节点 v 的所有 k 个邻居间边的数量， k 是节点 v 的度

$$CC_A = 2 * 1 / 3 * (3-1) = 1/3$$

聚类系数衡量的是：你（节点 V ）的朋友们（邻居），他们彼此之间是不是朋友？

理论： C_k^2 ， 实际： n 。

理解：对于这里的 A ，邻居有 BCD ，理论最大有 $C_3^2=3$ 条边，实际上只有 BC 这一条边。

聚类系数


是用来衡量网络中三角关系数量的指标

如果节点v1连接于节点v2，节点v2连接于节点v3，那么节点v3很可能与v1相连接。
这种现象被称为三角关系，它体现了部分节点间存在的密集连接性

对于有向网络，节点v的聚类系数定义为：

$$CC_v = \frac{n}{p_k^2} = \frac{n}{k_{out}(k_{out} - 1)}$$

其中n表示节点v的所指向节点间存在边的数量。



$$CC_A = \frac{1}{2 \times (2 - 1)} = \frac{1}{2}$$

这里的 k_{out} 指的是节点 v 的出度，对于 A 而言就是 2。

- 生物网络中通常具有较高的聚类系数。
- 高聚类系数意味着网络存在模块化 (Modularity) 结构。
- 这些模块 (Modules) 往往对应着执行特定生物学功能的功能单元，例如：
 - 蛋白质复合物 (Protein Complexes)
 - 信号通路 (Signaling Pathways)
- 模块的存在增强了系统的稳定性和鲁棒性。

拓扑系数(topology coefficient)

反映互作节点间共享连接比例的测度。其反应的是节点的邻居间被其他节点连接在一起的比例。


$$T_v = \frac{1}{|M_v|} \sum_{t \in M_v} C_{v,t} / \min \{k_v, k_t\}$$

$C_{v,t}$ 表示与节点v和节点t都连接的节点数。 M_v 为所有与节点v分享邻居的节点集合。

$$M_A = \{B, C, E\}$$

连通度

$$k_B=2, \quad k_C=3, \quad k_E=1$$



$$T_A = 1/3 * (1/2 + 1/3 + 1) = 11/18$$

介数中心性 (Betweenness)

σ_{ij} : 从节点 i 到 j 的最短路径总数。


σ_{ivi} : 从 i 到 j 的最短路径中经过节点 v 的数量。

定义：网络中所有最短路径中，经过某一个节点的路径数量的比例。

假设：一个节点如果位于许多其他节点对的最短路径上，那么它就越重要。它扮演着“桥梁”或“瓶颈”的角色

A的介数为多少？

$$B_v = \sum_{i \neq j \neq v \in V} \frac{\sigma_{ivj}}{\sigma_{ij}}$$



B: C, D, E	{B, A, D}	1
C: B, D, E	{C, A, D}	1
D: B, C, E	{D, A, B}, {D, A, C}, {D, A, C, E}	3
E: B, C, D	{E, C, B}, {E, C}, {E, C, A, D}	1

A的介数为6

要求A的介数，就看其他BCDE点到除了A点的其他点最短距离是否经过A，然后统计经过A的次数。比如B，他可以去CDE，只有BAD这条从B->D的路径经过A，所以这个就统计1次。以此类推，A的介数就是BCDE加起来，为6。


介数中心性 (Betweenness)

定义：网络中所有最短路径中，经过某一个节点的路径数量的比例。

假设：一个节点如果位于许多其他节点对的最短路径上，那么它就越重要。它扮演着“桥梁”或“瓶颈”的角色

A的介数为多少？

$$B_v = \sum_{i \neq j \neq v \in V} \frac{\sigma_{ivj}}{\sigma_{ij}}$$



B: 0
C: B 0
D: B, C {D, A, B}, {D, A, C} 2
E: B, C 0

A的介数为2

这个也是一样，只是这里只算出去的路径。

在信号转导网络中，介数中心性高的节点通常是连接不同信号通路的关键分子。


这些“瓶颈”节点是药物设计的重要靶点。抑制这些节点可以同时阻断多个下游通路。

紧密度(closeness)

是描述一个节点到网络中其他所有节点平均距离的指标

节点v的紧密度定义为

$$C_v = \frac{1}{N-1} \sum_{j \neq v \in V} d_{vj}$$



A节点的紧密度为1.25

为什么分母是N-1？因为一般不算自环，即排除自己和自己计算距离。

真实世界网络的共性：

1. 小世界现象 (Small-World Phenomenon)

在一个大规模的网络中，任意两个节点之间的平均路径长度 (L) 非常小。

2. 无标度特性 (Scale-Free Property)


无标度网络 (Scale-Free Network)

定义：其度分布遵循幂律分布 $P(k) \sim k^{-\gamma}$ 的网络。

“无标度”的含义：网络中没有一个“特征尺度”或“典型”的度。

节点的度可以跨越多个数量级。

关键特征：存在少数度极高的 Hub 节点。



✓无标度网络中大部分节点的连通度较低，但存在少数连通度非常高的枢纽节点（hub）

使网络连接在一起

✓枢纽节点的存在使得无标度网络对意外故障具有很强的鲁棒性。因为即使少数枢纽节点失效，网络整体的连通性仍然能够保持

✓无标度网络也因此对协同攻击更加脆弱。因为攻击者只需要集中攻击少数枢纽节点，就能够使整个网络瘫痪

重点理解无标度网络的生物学意义

鲁棒性：指网络在受到随机攻击（随机移除节点）时，其结构和功能仍能保持相对完整的能力。

原因：

- 网络中绝大多数是度很低的“普通”节点。
- 随机攻击有很大概率击中这些普通节点。
- 移除普通节点对网络的连通性影响很小。

生物学意义：细胞能够容忍大多数随机的基因突变而不崩溃，体现了生命系统的稳定性。

脆弱性：指网络在受到蓄意攻击（精确移除Hub节点）时，其结构会迅速崩溃。

原因：

- Hub节点连接了网络的大量部分。
- 移除一个Hub节点会使网络分裂成许多不连通的碎片。

Barabási-Albert模型

蛋白质互作网络中出现无标度特性的原因在于基因复制

- ✓ 在细胞分裂过程中复制产生的基因产物会与相同的蛋白发生相互作用。
- ✓ 与发生复制的蛋白连接的蛋白节点将会获得新的连接
- ✓ 因此，高度连接的节点更有可能与发生复制的基因产物发生互作，从而获得额外的连接，最终形成蛋白互作网络的无标度特性

网络模块

网络的“模块”(module)指网络间的节点存在着**内部彼此高度连接的子节点集合**，它们由许多分子相互结合形成的，有着稳定结构和功能的复合体

网络模块化的意义：

提高效率：模块化可以将复杂的功能分解成更小的、更易于管理的子功能，从而提高系统的效率

增强鲁棒性：模块化可以使系统更加鲁棒，因为即使其中一个模块出现故障，其他模块仍然可以正常工作

促进进化：模块化可以促进系统的进化，因为新的模块可以通过组合现有的模块来形成

生物分子网络的特性：

- 模块性
- 孤立性
- 层次性


网络模体/模序(network motif)

是指**网络中出现次数显著超过随机网络中出现次数的子网模式**。在某些网络中，特定出现的模体甚至是整个网络的基本组织形式，网络可以被看作是这些网络模体的组合

第三章 R语言与网络分析

首先复习一下R语言的基础知识，这里省略。

比如管道操作语法：



网络概念的回顾:

网络 (Graph): $G = (V, E)$

节点 (Vertex, V): 系统中的实体 (基因, 蛋白质, 细胞)。

边 (Edge, E): 实体间的关系 (相互作用, 调控, 代谢反应)。

属性 (Attribute): 节点或边的额外信息 (基因名, 蛋白功能, 相互作用强度)。


有向/无向: 关系是否有方向。

加权/无权: 关系是否有强度之分。

网络的数据结构:

邻接矩阵 (Adjacency Matrix)

- ❑ 一个 $N \times N$ 的方阵 (N 是节点数)。
- ❑ 矩阵 A 的元素 $A[i, j]$ 定义如下:
 - ✓ $A[i, j] = 1$: 如果节点 i 和 j 之间有边。
 - ✓ $A[i, j] = 0$: 如果没有边。
- ❑ 加权图: $A[i, j]$ 可以是权重值。
- ❑ 无向图: 矩阵是对称的 ($A[i, j] = A[j, i]$)。



优点: 速度快; 缺点: 对于**稀疏网络** (边远少于 N^2) 非常浪费空间。生物网络大多是稀疏的。(牺牲空间换速度)

改进: 使用稀疏矩阵, 只存有边的关系。使用Matrix包来构建:

`m2 <- sparseMatrix(i = ..., j = ..., x = 1)`

i 和 j 分别代表行和列索引, x 是填入的值。


```
> m2 <- sparseMatrix(i = c(1, 1, 1, 2, 2, 3, 3, 3, 4, 5), j = c(2, 3, 4, 1, 3, 1, 2, 5, 1, 2), x=1)
> m2
5 x 5 sparse Matrix of class "dgMatrix"

[1,] . 1 1 1 .
[2,] 1 . 1 . .
[3,] 1 1 . . 1
[4,] 1 . . . .
[5,] . 1 . . .
> rownames(m2) <- colnames(m2) <- letters[seq(5)]
> m2
5 x 5 sparse Matrix of class "dgMatrix"
  a b c d e
a . 1 1 1 .
b 1 . 1 . .
c 1 1 . . 1
d 1 . . . .
e . 1 . . .
```

比如这里的1, 2就填入1。

边列表

- ❑ 一个 $M \times 2$ 的列表或矩阵 (M 是边数)。
- ❑ 每一行代表一条边，包含两个元素：起点和终点。
- ❑ 可以增加第三列来表示权重。



```
> E1
      v1 v2
[1,] "A" "B"
[2,] "A" "C"
[3,] "A" "D"
[4,] "B" "C"
[5,] "C" "E"
```

优点:


节省空间，尤其适合稀疏网络。
直观，易于手动创建和理解。

缺点:

查找特定节点的邻居或判断两点是否相连比较慢。

邻接列表

- ❑ 一个长度为 N 的列表 (N 是节点数)。
- ❑ 列表的第 i 个元素是节点 i 的所有 **邻居节点** 的集合。
- ❑ 是空间和时间效率之间的一个很好的平衡。



```
> g <- list(A=c("B", "C", "D"), B = c("A", "C"), C=c("A", "B", "E"), D="A", E="C")
> g
$A
[1] "B" "C" "D"

$B
[1] "A" "C"

$C
[1] "A" "B" "E"

$D
[1] "A"

$E
[1] "C"
```

优点:

对稀疏网络友好，节省空间。
高效查找一个节点的所有邻居。

缺点:

实现比前两者稍复杂

R中实现网络分析的包:

Igraph和tidygraph

Igraph创建网络方法:

- `graph_from_data_frame()`: 从边列表（和节点属性表）创建，最常用。
- `graph_from_edgelist()`: 从边列表（两列矩阵）创建。
- `graph_from_adjacency_matrix()`: 从邻接矩阵创建。

```
# 1. 创建一个边列表数据框 (data frame)
# 第一列是起点，第二列是终点
edge_list <- data.frame(
  from = c("A", "A", "B", "C", "D"),
  to   = c("B", "C", "C", "D", "A")
)
# 2. 使用 graph_from_data_frame() 创建网络
g <- graph_from_data_frame(d = edge_list, directed = TRUE)
# 3. 查看网络基本信息 print(g)
```

```
g
GRAPH 8294389 DN-- 4 5 --
attr: name (v/c)
edges from 8294389 (vertex names):
[1] A->B A->C B->C C->D D->A
```

1. 创建一个邻接矩阵

```
adj_matrix <- matrix(
  c(0, 1, 1, 0, # A行
    0, 0, 1, 0, # B行
    0, 0, 0, 1, # C行
    1, 0, 0, 0), # D行
  nrow = 4,
  byrow = TRUE,
  dimnames = list(c("A", "B", "C", "D"),
                  c("A", "B", "C", "D"))
)
```

2. 使用 graph_from_adjacency_matrix() 创建网络

```
g_adj <- graph_from_adjacency_matrix(adj_matrix, mode = "directed")
```

```
g_adj
GRAPH 2979da8 DN-- 4 5 --
attr: name (v/c)
edges from 2979da8 (vertex names):
[1] A->B A->C B->C C->D D->A
```

访问节点和边:

V(g): 返回网络 g 的所有节点 (Vertex) 的序列。

E(g): 返回网络 g 的所有边 (Edge) 的序列; 或者用 `edge_attr(g, name = "xx")`

添加节点属性: `V(g)$xx <- c()`

添加边属性: `E(g)$xx <- c()`; 或者用: `g <- set_edge_attr(g, name = xx, value = xx)`

R软件可视化网络的包: `ggraph`, `ggtangle`

动态修改网络：添加/删除节点与边

- ✓ `add_vertices(g, nv)` : 添加 `nv` 个新节点。
- ✓ `add_edges(g, edges)` : 添加新边。
- ✓ `delete_vertices(g, v_seq)` : 删除指定的节点序列。
- ✓ `delete_edges(g, e_seq)` : 删除指定的边序列。
- ✓ `+` / `-` 运算符是更直观的语法糖。

删除节点 'C'

```
g_attr - vertex("C")
```

与C相关的边也会被删除

社区

- ❑ **社群（或模块）** 是网络中一些节点的集合，这些节点内部的连接非常紧密，而与网络其余部分的连接则相对稀疏。
- ❑ 在生物网络中，社群往往对应着**蛋白质复合物、信号通路或功能模块**。
- ❑ **社群发现 (Community Detection)** 是网络分析中的一个核心任务。

算法：

Girvan-Newman 算法：通过不断移除网络中“最关键”的边（边介数 (Edge Betweenness) 最高的边），直到网络分裂成不同的社群。 **函数**: `cluster_edge_betweenness()`

Louvain 算法：

初始化: 每个节点自成一个社群。

局部优化:

依次遍历所有节点，尝试将其分配至其邻居所在的社群中，选择能使**模块度增益最大**的分配方案。

聚合: 将步骤2中形成的社群视为新的“超级节点”，构建一个新的网络。

重复步骤2和3，直到模块度不再增加。

模块度是衡量一个网络社群划分方案好坏的指标

路径分析:

- ❑ `shortest_paths(g, from, to)`: 查找从 from 到 to 的所有最短路径。
- ❑ `all_simple_paths(g, from, to)`: 查找从 from 到 to 的所有不含重复节点的路径。
- ❑ `distances(g, v, to)`: 计算从节点 v 到 to 的最短路径长度 (距离)。

网络格式转换:

`Read_graph(filename, format)`

`Write_graph(graph, filename, format)`

思考题 (可能出大题):

假设你手头有一个酵母菌的PPI网络, 你的任务是识别其中的功能模块, 并预测一个未知功能蛋白质的功能。你如何发现网络中的模块? 要解释识别出来的蛋白网络功能模块, 可以采用什么分析?

模块可以用聚类方法来识别 (louvain、MCL、MCODE) + 聚类打分
功能模块注释: 富集分析/随机游走通路打分进行注释

第四章 基因调控网络

基因调控网络定义:

广义上, 一个由基因、RNA和蛋白质等分子组成的复杂网络, 它们通过相互作用, 共同控制细胞内所有基因的表达水平。GRN是细胞的中央处理单元 (CPU)”或“操作系统”, 负责执行生命的程序。

基因表达调控主要发生在两个关键层面:

1. **转录层面** (Transcription): 转录调控网络 (控制基因被转录成 mRNA 的速率)。
2. **转录后层面** (Post-Transcription): 转录后调控网络 (控制 mRNA 的稳定性、翻译效率)

一、转录调控网络

用来描述转录因子和靶基因的关系

转录因子结合 motif表示方法: DNA 共有序列、IUPAC 简并码、位置频率矩阵、序列标识图

转录因子结合模体

表示方法三:

序列标识图 (sequence logo)

序列标识图第j位上某个碱基i的高度 $height_{ij} = q_{ij} \times R_j$

其中, $R_j = 2 - (H_j + e_n)$

H_i 是位置i处的信息熵: $H_i = -\sum_{j=1}^4 q_{i,j} \times \log_2 q_{i,j}$

e_n 是针对小样本的近似矫正: $e_n = \frac{1}{\ln 2} \times \frac{3}{2n}$ n 为序列数

A	0.09	0.09	0.27	0.18	...	0.09
C	0.55	0.36	0.09	0.64	...	0.27
G	0.09	0.27	0.45	0.18	...	0.55
T	0.27	0.27	0.18	0.00	...	0.09

位置频率矩阵



转录调控数据库:

JASPAR、TRRUST、hTFtarget、plantTFDB (植物 tf)

CHIP-seq、CUT-TAG 用于识别 tf-motif

二、转录后调控网络

转录后调控: 真核生物基因的转录产物进行的一系列修饰与加工。

包括:

- ✓ mRNA 前体的剪切与加工
- ✓ mRNA 从细胞核转运到细胞质的过程与定位
- ✓ mRNA 的稳定性及其降解过程

转录后调控网络 (Post-Transcriptional Regulatory Network, PTRN):

核心分子: microRNAs (miRNAs), 长链非编码 RNAs (lncRNAs), 环状 RNA(circRNA), RNA 结合蛋白 (RBPs)。

作用核心: mRNA 分子本身。

关注问题: mRNA 的命运——降解、稳定或被翻译。

定义: 描述了转录后调控因子 (如 miRNA) 如何影响其靶标 mRNA 分子的网络

miRNA: 一类短的内源性的单链非编码 RNA 分子, 成熟体只有 22 个核苷酸左右, 主要在转录后水平通过与靶 mRNA 互补配对的方式抑制靶 mRNA 的翻译或者直接降解 mRNA。

转录后调控数据库：miRBase、TarBase

构建基因调控网络的方法：

相关性网络、基于互信息的方法、基于回归的方法

相关性网络：

最简单的方法。

步骤：

- ✓ 计算所有基因对之间的 Pearson 或者 Spearman。
- ✓ 设定一个相关性阈值 τ (如 $|r| > 0.8$)。
- ✓ 如果两个基因的相关性绝对值超过阈值，就在它们之间画一条无向边。

也称**共表达网络** (Co-expression Network)。

缺点：无法区分直接和间接关联、**无法确定调控方向**、本质不是因果调控网络

互信息：

度量两个随机变量之间相互依赖性的信息论指标。**理论上能捕捉非线性关系**，比相关性系数更普适。

□ **步骤：**

- 计算所有基因对之间的互信息。
- 设定阈值，构建一个稠密的初始网络。
- 核心步骤：“剪枝”，去除间接连接。

代表性算法：ARACNE，对三角关系进行剪枝

缺点：**无法确定边的方向**

回归：

□ **核心思想：**将每个基因的表达水平建模为其潜在调控因子的函数。

□ **模型：** $\text{Expression}(\text{Gene}_i) = \beta_1 * \text{Expression}(\text{Gene1}) + \beta_2 * \text{Expression}(\text{Gene2}) + \dots + \varepsilon$

□ 这是一个经典的特征选择 (Feature Selection) 问题：对于基因 i ，我们需要从几百上千个 gene 中，找出那一小部分真正与之有调控关系的 gene（即系数 β 不为零的项）。

算法：GENIE3

应用：

网络拓扑分析

网络中心性测量可以帮助确定**哪些 TF 或基因对网络的连通性或信息流更重要**。网络中心性度量的一些例子包括**度中心性**、**紧密度**、**介数中心性**和**特征向量中心性**。这些措施有助于识别在不同生物学环境中驱动细胞命运变化的 TF，例如直接谱系重编程，人类心肌梗死和小鼠发育。

比较分析

TF 活性推断---SCENIC

Step1. 用 GENIE3 推断共表达模块。首先输入一个基因表达矩阵，然后使用随机森林模型，试图用所有 TF 的表达量来预测某个基因的表达量，最后输出共表达模块，即一个 TF 和一群跟它表达趋势高度相关的基因。

Step2. 通过 motif 分析，提纯调控子。对于某个 TF，找到对应的共表达基因集合，去这些基因的启动子或者增强子区域找 motif，然后查数据库，如果这个 TF 没有与 motif 的关联数据，就认为这对 tf-target gene 只是共表达，而不是实际调控。最后输出一个确定的调控子-靶点。

Step3. 在每个单细胞中量化调控子活性（**AUCe11 打分**）。在每一个单独的细胞里，把所有基因按表达量从高到低排序。对某个 regulon 里的靶基因集合，是否在这个细胞里富集在排名的前列（打分）。最后产生一个矩阵，行是 tf，列是细胞。

总结：

基因调控网络的探索，遵循着一个经典的科学范式：

- **测量 (Measure)**：通过 RNA-Seq 等技术获取基因表达数据。
- **建模 (Model)**：使用计算方法从数据中推断 GRN 的结构，形成假说。
- **预测 (Predict)**：基于网络模型，预测关键调控因子或药物干预的后果。
- **验证 (Validate)**：通过 ChIP-Seq、CRISPR 等实验来检验预测，并将新知识反馈到模型中。

思考题（可能会出大题）

- 我们推断出的 GRN 模型通常忽略了哪些生物学复杂性？

忽略了 TF 翻译后修饰。TF 的 mRNA 表达高不代表 TF 蛋白有活性（RNA-seq 的缺陷）。

忽略了表观遗传与染色质状态。如果染色质是关闭的，TF 是无法结合的，所以要结合 atac-seq 和甲基化层面的结果来分析。

3D 基因组结构。线性距离远的基因可能在空间上很近。要结合 hi-c 来分析。

时间延迟。TF 表达变化-靶基因表达变化是需要时间的。而 RNA-seq 是快照，很难捕捉到严格的因果时间滞后效应

- 目前 GRN 研究领域面临的最大的挑战是什么？

相关性不等于因果推断

缺乏金标准，没有 ground truth 来验证算法的准确性。

细胞环境特异性：同一个 TF 在肝脏细胞和神经细胞里调控的靶基因可能完全不同（因为辅助因子、染色质状态不同）。目前的通用模型很难精准预测这种环境特异性的动态变化。

- 结合 AI（如 AlphaFold 等结构预测工具）和新的实验技术（如空间转录组学），可能如何构建一个更完整、更精确、包含更多维度信息的“下一代”基因调控网络模型？

引入空间维度

引入结构维度

虚拟细胞

- ❑ 如何利用基因调控网络（GRN）来分析癌细胞的耐药性？
- ❑ • **Input**: 测序数据（耐药 vs 敏感）。
- ❑ • **Inference**: 使用 GENIE3/SCENIC 构建两个状态的 GRN。
- ❑ • **Topology Analysis**: 计算拓扑性质（度、聚类系数），找差异。
- ❑ • **Identification**: 锁定耐药特异性的 **Hub TF** 和 **重连边**。
- ❑ • **Validation**: 在实验中敲除该 TF，看是否能恢复对药物的敏感性。

- ❑ WGCNA 与 GENIE3 方法可以如何结合以更好地分析相应的数据？

步骤 1：利用 WGCNA 进行模块化降维与表型筛选（缩小范围）

- **操作**：首先对全基因组表达数据进行 WGCNA 分析，识别共表达模块。
- **目的**：将 20,000+ 个基因缩减为 10-20 个功能模块。
- **筛选**：计算模块与感兴趣表型（如“药物敏感性”）的相关性，锁定**“最相关模块”**（Key Module）。
- **意义**：这一步排除了大量背景噪音基因，确保后续分析聚焦于与生物学问题高度相关的功能单元。

步骤 2：在关键模块内部运行 GENIE3（建立方向）

- **操作：**提取“最相关模块”内的所有基因（通常几百到一千个），仅针对这些基因运行 GENIE3（或者将该模块内的基因作为 Target，全基因组 TF 作为 Regulators）。
- **目的：**构建**模块内调控网络 (Intra-modular Regulatory Network)**。
- **意义：**WGCNA 告诉我们这些基因“在一起工作”，GENIE3 则进一步揭示“由于 TF X 的驱动，它们才在一起工作”。这赋予了无向的共表达模块以内部结构和方向。

步骤 3：基于双重验证识别“关键驱动因子”（Master Regulators）

- **操作：**寻找同时满足以下两个条件的基因：
 1. 在 **WGCNA** 中：是模块内的 **Hub Gene**（Module Membership, kME 值很高），说明它位于模块拓扑结构的中心。
 2. 在 **GENIE3** 中：具有极高的 **Importance Score**（即作为 TF 调控了模块内大量其他基因）。
- **结论：**如果一个 TF 既处于共表达网络的中心（连接度高），又是调控网络的顶层（因果权重高），那么它是该表型真正的 **Master Regulator**。

第五章 蛋白互作网络与数据资源

在细胞内，蛋白质不是单独发挥功能，往往通过直接或间接的方式与其他蛋白质相互作用，形成稳定或动态的蛋白质复合物，参与调控重要的生物学过程。

蛋白质之间的相互作用并非依靠牢固的共价键，而是多种较弱的**非共价键**协同作用的结果。

主要包括：

- ✓ 氢键
- ✓ 离子键（静电作用）
- ✓ 疏水作用
- ✓ 范德华力

相互作用的类型：

稳定的相互作用：比如核糖体和血红蛋白（亚基）

瞬时/暂时的相互作用：比如激酶与底物，受体与配体

三维结构基础：

域-域相互作用：最常见

域-短肽/基序相互作用：

肽-肽相互作用：

检测 PPI 的实验方法：

酵母双杂交系统：适用于检测“一对一”的直接互作。

亲和纯化-质谱联用：适用于鉴定“多对多”的复合物成员。


共分离质谱: 特别适用于绘制细胞或组织中完整的蛋白质相互作用网络, 无需依赖特定的抗体或标记技术。

酵母双杂交原理:

背景: 酵母的转录因子 (如GAL4) 有两个可以物理分离的功能域:

DNA结合域 (Binding Domain, BD): 负责结合在特定DNA序列上。

转录激活域 (Activation Domain, AD): 负责“招募”RNA聚合酶, 启动基因转录。



核心思想: 如果我们将BD和AD分别与两个待测蛋白X和Y融合, 只有当X和Y发生相互作用时, 分离的BD和AD才能被重新拉到一起, 恢复转录因子的功能, 从而激活一个“报告基因”的表达。

20

Y2H 的优缺点评估

优点:

- ✓ 检测直接互作: 能有效发现“一对一”的直接物理结合。
- ✓ 灵敏度高: 能检测到较弱或瞬时的相互作用。
- ✓ 操作相对简单: 适用于大规模、高通量筛选。


缺点 (高假阳性/高假阴性):

- ✓ 假阳性: 某些蛋白自身就能激活转录; 在非生理环境 (酵母细胞核) 中发生的非特异性结合。
- ✓ 假阴性: 融合蛋白错误折叠; 互作需要翻译后修饰; 互作发生在细胞核外。

亲和纯化-质谱（AP-MS）联用原理：

根本目标是回答一个问题：“蛋白质A在细胞里都和谁组成了复合物？”

将目标蛋白（诱饵蛋白，Bait）与特定的亲和标签（如His、Strep-tag）融合，利用标签与特异性基质的强亲和力，从细胞裂解液中分离出目标蛋白及其结合的蛋白复合物并进行质谱鉴定。



24

优点

（1）**高通量**：一次实验可鉴定数十至数百个互作蛋白，适用于构建蛋白质相互作用网络。

（2）**接近细胞状态**：在细胞内表达的带标签蛋白保留了其天然修饰和相互作用环境。

缺点

（1）**假阳性**：标签蛋白很容易在细胞中过表达，导致出现由于蛋白表达量过高所产生的假阳性结果。

（2）**难以鉴定到互作较弱和瞬时的蛋白**：有些蛋白在细胞中互作很弱，在 AP-MS 实验中难以鉴定到。


（3）**难以反映真实的细胞内互作情况**：可能会出现虽然细胞中这两个蛋白不在同一位置定位，但 AP-MS 中却能鉴定到二者互作的情况。

共分离质谱：

当两个或多个蛋白质在细胞中以复合物的形式存在时，它们在物理分离过程中会发生共同迁移，结合质谱分析即可以鉴定到互作蛋白。

操作流程

- (1) 样品制备：从细胞或组织中提取蛋白质，通常在非变性条件下裂解细胞。同时可选择加入化学交联剂以稳定弱相互作用的复合物。
- (2) 使用色谱技术（如SEC或IEX）等方法将裂解液分离成多个组分。SEC按分子量分离，而IEX按电荷分离。
- (3) 收集分离后的组分，通常为几十到几百个馏分，将对应馏分的组分进行质谱鉴定。



优点

- (1) 无需标记：CF-MS 技术中不需要抗体或外源性标签（如 GFP），避免了标记可能对蛋白质功能或相互作用的干扰。
- (2) 高通量：能够一次性检测数千个蛋白质相互作用，适用于绘制全局蛋白质相互作用网络。
- (3) 天然状态：分析的是细胞内天然蛋白质复合物，结果更接近生理条件。
- (4) 多维度信息：不仅能鉴定相互作用，还能提供复合物的尺寸、丰度等信息。

缺点

- (1) 复杂数据分析：生成的数据量庞大，洗脱曲线的相似性分析依赖复杂的生物信息学工具，对计算能力和专业知识要求较高。
- (2) 分辨率有限：分离技术的分辨率（如 SEC 的分子量范围）可能不足以区分相近大小的复合物，或者无法检测瞬时/弱相互作用。
- (3) 实验成本高：需要高精度的色谱设备和质谱仪，样品制备和分析耗时耗力。
- (4) 丰度依赖性：低丰度蛋白质或复合物可能难以检测，敏感性受限于质谱仪性能和样品量。

PPI 数据库的公开资源

主要数据库：

主要数据库专门从同行评审的科学出版物中收集实验性分子相互作用数据。[BioGRID](#)、[IntAct](#)、[MINT](#) 和 [MatrixDB](#) 是这类数据库的例子

次要数据库，也称为元数据库，旨在将多个主要数据库策展的数据整合到一个综合存储库中。APID 和 PINA 是这类数据库的例子。

最后，[预测性数据库](#)结合了从主要数据库中获取的实验推断数据以及分子相互作用的计算预测。例如 STRING 和 UniHI

PPI 网络拓扑分析和功能模块分析

MCODE (Molecular Complex Detection) 是一个经典的、在 Cytoscape 等软件中广泛应用的模块发现算法。

算法思想:

加权: 首先根据节点的[局部邻域密度](#)给每个节点打分。

播种: 从得分最高的节点开始，作为“种子”，向外扩展，不断吸纳邻近的高分节点，形成一个初始模块。

过滤: 对形成的模块进行过滤，去除不满足特定大小或密度阈值的模块。

产出: 一系列高密度连接的蛋白质网络，这些子网络很可能对应着生物学上的蛋白质复合物或功能通路。

思考题:

假设你通过基因组测序，发现了一个未知蛋白质，称之为 Protein X。要如何进行其功能预测？

构建 PPI 网络，通过社群发现算法进行聚类，富集分析进行功能注释；通过随机游走算法对该蛋白进行功能打分。

假设你获得了一个包含 5000 个蛋白和 20,000 条互作边的网络。请设计一个简单的算法流程，用于识别其中潜在的蛋白质复合物 (protein complexes)

- 数据预处理（构建图，通过互作得分或者度过滤节点）
- 核心聚类，使用 MCL 或者 MCODE
- 聚类后处理，对聚类打分
- 选择高分 cluster 进行功能富集注释

第六章 代谢网络与信号转导途径

代谢通路 (metabolic pathway) 是指细胞中代谢物在**酶**的作用下转化为新的代谢物过程中所发生的一系列**生物化学反应**。

代谢网络则是指由**代谢反应**以及调节这些反应的**调控机制**所组成的**描述细胞内代谢和生理过程**的网络。

- 完全网络：完整保存代谢通路中的各个反应，以及每个反应中的酶、底物与产物，如果同一个酶参与不同反应则在网络中应以**不同节点**表示。
- 多反应物网络：包含参与生物通路的代谢物，**即底物、酶、产物的有向网络**。
- 主要反应物网络：只包含主要代谢底物指向主要产物的网络

代谢网络的构建与表达

节点：代谢物

边：生化反应

注意酶是反应的催化剂，而不是网络中的节点！！

（考试）化学计量矩阵的含义

化学计量矩阵

化学计量矩阵 (Stoichiometric Matrix)，是描述代谢网络拓扑结构的“通用数学语言”

□ 定义：一个 $m \times n$ 的矩阵，其中：

- ✓ m 是网络中**代谢物 (Metabolites)**的数量。每一行，代表一种代谢物。
- ✓ n 是网络中**反应 (Reactions)**的数量。每一列，代表一个反应。

□ 矩阵元素 S_{ij} 的含义：





- ✓ 代表代谢物 i 在反应 j 中的化学计量系数 (Stoichiometric Coefficient)。
- ✓ 约定俗成的规则：
- ✓ 如果代谢物 i 是反应 j 的**反应物 (Reactant)**，则 S_{ij} 为**负数 (被消耗)**。
- ✓ 如果代谢物 i 是反应 j 的**产物 (Product)**，则 S_{ij} 为**正数 (被生成)**。
- ✓ 如果代谢物 i 不**参与**反应 j ，则 S_{ij} 为 **0**。

S矩阵，是整个代谢网络分析的基石。它将复杂的生物化学反应，编码成了一个计算机可以处理的、简洁的数字矩阵。

举个例子：

化学计量矩阵

Reaction Network



Stoichiometric Matrix

	R1	R2	R3	R4	R5	R6
A	-2	-1	-1	1	0	0
B	-1	-3	2	-4	-2	3
C	1	1	0	0	1	-1
D	3	0	1	1	-1	1
E	0	1	1	0	2	-4

假设我们有这样一个简单的代谢网络：

代谢物 (Metabolites): 4种 (A, B, C, D)

反应 (Reactions): 3个 (R1, R2, R3)

反应列表:



为这个网络，构建一个 S 矩阵。

	R1	R2	R3
A	-1	0	0
B	1	-1	-1
C	0	1	0
D	0	0	1

GPR 关联 (Gene-Protein-Reaction Association):

是一个逻辑表达式，它精确地描述了哪个基因（或哪些基因）负责催化哪个反应。

两种主要的复杂对应关系：

1. 同工酶 (Isozymes): 不同的基因，编码了不同的酶，但它们都能催化同一个反应。

✓ 逻辑关系: (基因 A) OR (基因 B) $\Rightarrow$ 反应 1

2. **酶复合物 (Enzyme Complex)**: 多个不同的蛋白质亚基, 必须**共同组装**成一个复合物, 才能催化一个反应。

✓ **逻辑关系**: (基因 A) AND (基因 B) => 反应 2

GPR 关联是至关重要的。它将抽象的化学反应网络, 锚定到了一个具体物种的基因组之上, 使得我们可以通过“基因敲除”的模拟, 来研究网络的功能。

GPR关联 (Gene-Protein-Reaction Association):

基因-反应关联矩阵 (Gene-Reaction Matrix), 一种二进制矩阵 (只包含0和1):

行 (Rows) 代表**基因 (Genes)**。

列 (Columns) 代表**反应 (Reactions)**。

矩阵中的值 (Value): 如果基因为 i , 反应为 j , 那么矩阵中 (i, j) 位置的值为:

1: 如果基因 i 参与了反应 j 。

0: 如果基因 i 没有参与反应 j

什么是 GEM?

- ✓ 是一个物种**完整代谢网络**的数学表达。
- ✓ 包含了由该物种基因组所编码的所有已知的代谢反应、代谢物和转运蛋白。
- ✓ 本质上, 是一个包含了成百上千个反应和代谢物的、巨大的、物种特异性的 **S 矩阵 + GPR 关联列表**。

为何重要?

- ✓ GEM 代表了一个生物体代谢能力的**理论上限 (Theoretical Maximum)**。
- ✓ 它是一个可计算的平台, 使我们能够在系统层面, 预测细胞在不同遗传和环境条件下的****表型 (Phenotype)****, 比如生长速率、基因必需性等。
- ✓ GEM, 是系统生物学和代谢工程领域, **最有力的分析工具之一**。

流量平衡分析 (Flux Balance Analysis, FBA)。

采用最优化目标函数的方法来模拟系统的稳态最优代谢通量分布

- 设定目标函数：细胞生长最优、ATP消耗最低、发酵产物产量最高等
- 采用线性规划求解Linear Programming (LP)

两个假设：

□ 稳态假设 (The Steady-State Assumption)

内容：对于网络中所有的中间代谢物**，其总生成速率必须精确地等于其总消耗速率。

推论：这些中间代谢物的浓度，在一个特定的时间尺度上，是保持不变的。

本质：这是质量守恒定律在开放生物系统中的直接体现。

□ 优化假设 (The Optimization Assumption)

内容：细胞的代谢网络，其运行方式并不仅仅是满足质量守恒，而是在此基础上，会朝着一个或多个特定的生物学目标进行优化。

推论：在所有“可能”的流量分布中，细胞会选择那个能使其“目标函数”达到最优（通常是最大化）的特定分布。

本质：这是自然选择和进化在分子层面的体现。

数学表达： $S \cdot v = 0$

✓ S : $m \times n$ 化学计量矩阵 (m 个代谢物, n 个反应)。

✓ v : 一个 $n \times 1$ 的通量向量 (Flux Vector)。它的每一个元素 v_j ，代表了反应 j 的速率。

✓ $S \cdot v$: 这个矩阵乘法的结果，是一个 $m \times 1$ 的向量。它的每一个元素 $(S \cdot v)_i$ ，代表了代谢物 i 的净变化速率。

方程的意义：

$(S \cdot v)_i = 0$ 意味着，对于第 i 个代谢物，其（所有生成它的反应速率之和）-（所有消耗它的反应速率之和）= 0。

仅仅有 $S \cdot v = 0$ 是不够的，因为它允许反应速率 v 为任意大的值。需要根据热力学和环境条件，为每个反应的“通量”设定一个合理的上下限

$v_{\min} \leq v \leq v_{\max}$ capacity constraints

所有这些约束 ($S \cdot v = 0$ 和容量约束) 共同作用，会定义出一个“可行解空间” (Feasible Solution Space)。

为了从无数个可行解中找到那个“最优解”，我们需要引入“目标函数”。

目标函数 (Objective Function):


一个希望最大化 (或最小化) 的生物学目标。

数学形式: $Z = c \cdot v$ ，其中 c 是一个权重向量，定义了每个反应对总目标的“贡献”。

FBA 的实际应用中，90%以上的情况，使用的都是“最大化生物质合成”作为目标函数。

“生物质反应” (biomass reaction) 是一个虚拟反应，代表细胞合成单位生物量所需的所有前体物质 (如氨基酸、核苷酸、脂类、辅因子等) 及其化学计量比例。

FBA 总流程:



简单而言，FBA 就是在稳态假设下，利用线性规划，在约束条件内寻找能让生物生长最大化的代谢通量分布。

激酶 (Kinase): 负责“开”

能将 ATP 上的一个高能磷酸基团，共价连接到靶蛋白的特定氨基酸残基上 (通常是丝氨酸、苏氨酸或酪氨酸)。

这个带负电的磷酸基团，会像一块磁铁一样，改变靶蛋白的构象，从而激活或 (在少数情况下) 抑制靶蛋白的功能。

磷酸酶 (Phosphatase): 负责“关”

水解掉靶蛋白上的磷酸基团，使其恢复到原来的状态。

这个过程确保了信号是可逆的、动态的。

信号转导网络:

节点为蛋白，边为分子间的相互作用

MAPK 信号通路

MAPK: 丝裂原活化蛋白激酶, 是一种能诱导细胞分裂 (有丝分裂) 的信号分子的活化蛋白激酶

核心结构:

一个三层的激酶级联放大模块。

MAPKKK $\rightarrow$ MAPKK $\rightarrow$ MAPK

□ 短期调控:

- ✓ 机制: 翻译后修饰 (Post-Translational Modification, PTM), 最主要的是磷酸化。
- ✓ 作用对象: 直接作用于已存在的代谢酶。
- ✓ 效果: 快速改变酶的催化活性 或定位。

□ 长期调控:

- ✓ 机制: 转录调控 (Transcriptional Regulation)
- ✓ 作用对象: 调控编码代谢酶的基因。
- ✓ 效果: 改变代谢酶的合成速率, 从而改变细胞内酶的总量。

□ 信号网络:

- ✓ 形式: 通常是有向图, 或者基于布尔逻辑 (ON/OFF) 的规则网络。
- ✓ 描述: 信息流的因果关系 (‘A’ 激活 ‘B’)。
- ✓ 语言: 逻辑和拓扑。

□ 代谢网络 (FBA):

- ✓ 形式: 化学计量矩阵 S 。
- ✓ 描述: 质量的平衡和流动 ($A + B \rightarrow C$)。
- ✓ 语言: 线性代数和优化。

思考题:

如何建立一个“翻译规则”, 将信号网络模型输出的“状态” (如 Akt 激酶是 ON 还是 OFF), 转化为 FBA 模型能够理解的“约束” (如某个反应 v 的上下限应该被调整)?

建立“翻译规则”的核心是将信号网络输出的离散状态 (如激酶的 ON/OFF) 映射为 FBA 模型中的连续约束条件 (即反应速率的上下限 $v_{\min}$, $v_{\max}$)。

具体做法, 比如可以采用布尔逻辑映射:

- **规则设定:** 如果信号模型判定某个调控因子为“关闭”状态 (0), 则将其控制的代谢反应通量上限强制设为 0 (即 $UB=0$)。

- **效果：**这样信号网络就能通过动态改变 FBA 的**解空间边界**，来决定代谢网络在特定时刻“能做什么”，从而模拟细胞的调控机制。

但是生物反应并不是全或无的，比如说激酶的活性是处于一个 0-1 之间的状态，也是有活性的，这样可以考虑进行定量映射：

我们不再直接把反应设为 0 或 100%，而是计算一个 **调节系数 (Regulation Coefficient)**，记为 α (通常 $0 \leq \alpha \leq 1$)。


- 原来的约束: $0 \leq v \leq v_{max}$
- 新的约束: $0 \leq v \leq \alpha(\text{Signal}) \times v_{max}$

这里假设了酶的活性和反应强度成正比，通过更新 V_{max} ，从而来限制可行空间。

第七章 生物网络构建方法

基因共表达网络


- ❑ **核心假设 (Guilt-by-Association):**如果一群基因在许多不同的生理或病理条件下，其表达水平总是同步地上升或下降，那么我们有理由相信，它们很可能参与了同一个生物学过程，或者受到了同一个上游信号的调控。
- ❑ **网络构成：**
 - **节点 (Node):** 单个基因。
 - **边 (Edge):**代表两个基因表达谱之间的“相关性”强度。边通常是**无向的**，表示一种对称的关联。
- ❑ **生物学问题：**
 - 主要用于发现“**功能模块**” (**Functional Modules**)。
 - 对于一个功能未知的基因，我们可以通过分析它的“邻居”是谁，来预测它的潜在功能。



基因调控网络

基因调控网络

- 核心目标：从“相关性”迈向“因果性”。我们不仅想知道哪些基因一起变化，更想知道是谁**导致**了谁的变化。
- 网络构成：
 - 节点 (Node): 通常分为两类，**转录因子 (TFs)** 和**靶基因 (Target Genes)**。
 - 边 (Edge): 代表一种“**调控**”关系。边必须是有向的 (Directed)，箭头从转录因子指向它所调控的靶基因。
- 生物学问题：
 - 揭示细胞生命活动的**调控关系**。
 - 鉴定在特定生命过程（如细胞分化、疾病发展）中，起主导作用的“**关键调控因子**” (Master Regulators)



蛋白质互作网络


蛋白质-蛋白质相互作用(PPI)网络

- 核心目标：
 - 描绘细胞内的“物理社交网络”。基因产物--蛋白质，很少单独行动，它们通过物理结合，形成各种功能复合物。
- 网络构成：
 - 节点 (Node): 单个蛋白质。
 - 边 (Edge): 代表两个蛋白质之间存在**直接的、物理上的结合**。边通常是无向的。
- 生物学问题：
 - 鉴定构成某个“**蛋白复合物**”的所有成员。
 - 发现蛋白质的功能伙伴，从而推断其功能。

信号通路网络

信号通路网络

- ❑ 核心目标：追踪细胞内“信息”的流动路径。细胞如何感知外部信号，并将其一步步传递到细胞核，最终引起反应？
- ❑ 网络构成：
 - 节点 (Node): 主要是信号蛋白，如激酶、磷酸酶、G蛋白等。
 - 边 (Edge): 代表一次“信号传递事件”，最常见的是**磷酸化**。边必须是有向的，代表信息流动的方向。
- ❑ 生物学问题：
 - 重构从细胞膜受体到最终效应子的完整信号级联反应。
 - 理解药物（如激酶抑制剂）是如何通过阻断网络中的特定节点，来发挥作用的。



基因共表达网络的构建：

- ❑ 输入数据：一份经过**预处理和标准化**的“基因表达矩阵”。
- ❑ 格式 (Format):
 - 行 (Rows): 代表不同的基因。通常在人类中有大约 20,000 多个蛋白质编码基因。
 - 列 (Columns): 代表不同的样本。这些样本可以是不同的病人、细胞系、处理条件或时间点。
 - 单元格的值 (Value): x_{ij} 代表基因 i 在样本 j 中的表达丰度。
- ❑ 数据预处理：
 - 在进行计算之前，原始的测序数据必须经过严格的质量控制、批次效应校正和标准化。这一步对于结果的可靠性至关重要。我们可以暂时假设，我们拿到手的数据，已经是高质量的了。

相似性的量化方法：

- ❑ 最常用的相似性度量指标有三种：
 - **皮尔逊相关系数** (Pearson Correlation Coefficient)
 - 最常用，衡量的是**线性关系**的强度。
 - **斯皮尔曼等级相关系数** (Spearman Rank Correlation Coefficient)
 - 只关注排名，而不是真的绝对值；用排名替换原始值

- 对异常值和非线性关系更鲁棒。
- 互信息 (Mutual Information)
- 理论上最强大，可以捕捉复杂的非线性关系。

互信息补充：

为了捕捉非线性关系。

$$I(X; Y) = \sum_{x \in X} \sum_{y \in Y} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$$

- 直观解释：“在知道基因 Y 的表达水平后，我们对基因 X 表达水平的‘不确定性’减少了多少？” 如果减少得多，说明两者关系密切。

从相似性到连接，构建邻接矩阵

得到了相似性之后，到底怎么样才算共表达？

硬阈值法通过设置一个绝对的相关性门槛，来判定两个基因是否共表达

缺点：信息丢失严重（相关性强弱具有不同意义）；阈值选择的主观性

代替：使用软阈值法进行处理：

软阈值法

- 软阈值的核心思想：对相关性进行一次“惩罚性”的加权变换，而不是“一刀切”。
- 变换公式：
 - $\text{Adjacency}_{ij} = |\text{Correlation}_{ij}|^\beta$ ，参数 β 是一个大于1的幂指数，我们称之为“软阈值”。
- 优点：
 - 保留连续性：输出的邻接值，是0到1之间的连续数值，形成一个“加权网络”。相关性0.99和0.81的连接，其权重依然有显著差异。
 - 惩罚弱相关，奖励强相关：
- 例子如(假设 $\beta=6$):
 - ✓ 一个弱相关 $r=0.2$ ，其邻接权重变为 $0.2^6=0.000064$ ，被极大地抑制了，接近于0。
 - ✓ 一个强相关 $r=0.8$ ，其邻接权重为 $0.8^6 \approx 0.26$ ，虽然也被惩罚，但仍然保留了相当大的权重。
 - ✓ 一个极强相关 $r=0.95$ ，其邻接权重为 $0.95^6 \approx 0.73$ ，保留了很高的权重。
- 这种方式，既可以将噪声（低相关性）压制下去，同时保留了强信号。

对相关性进行幂次运算。Beta 叫做软阈值，就是相关性上面的指数。


意义：惩罚弱相关，奖励强相关。（强者越强弱者越弱）

如何选择软阈值？

β 值选择 选择一个 β 值，使构建出来的网络，其拓扑结构，最接近于真实生物网络普遍具有的“无标度”特性。

- 操作流程：
 1. 程序会尝试一系列的 β 值（例如，从1到20）。
 2. 对于每一个 β 值，它都会构建一个加权网络，并计算这个网络的节点度分布。
 3. 然后，它会计算这个节点度分布，与理想的“幂律分布”，在对数坐标下的线性相关性的平方，也就是 R^2 (Scale-Free Topology Fit Index)。
 4. R^2 的值越接近1，说明网络越符合无标度特性。
- 选择标准：

通常选择第一个，能够使 R^2 值达到一个较高水平（通常推荐 > 0.85 ）并且趋于平稳的 β 值。



简单来说就是尝试不同的软阈值，看看哪个软阈值最能代表无标度的网络特性（服从幂律分布）。

基因调控网络 GRN 的推断

要推断出 TF 与靶基因之间的调控关系，我们可以从两个截然不同的角度去寻找证据。这形成了 GRN 推断的两大主流方法学派。

- ❑ 基于“物理相互作用”的推断 (Physics-Based)
 - 核心问题：“这个 TF 能不能物理结合到那个靶基因的 DNA 上？”
 - 寻找的证据：TF 与 DNA 的物理结合证据。
 - 主要技术：ChIP-seq, ATAC-seq, DNA 序列模体分析。
 - 优点：提供直接的物理证据，可信度高。
- ❑ 基于“表达数据”的推断 (Expression-Based)
 - 核心问题：“这个 TF 的表达变化，会不会引起那个靶基因的表达变化？”
 - 寻找的证据：基因表达水平之间的统计依赖关系。
 - 主要技术：信息论方法 (ARACNe), 回归模型 (GENIE3) 等。
 - 优点：反映的是功能性的调控，不依赖于物理结合的先验知识。
- ❑ 一个完整的 GRN 研究，往往需要将两种思想流派的证据进行整合。

结合扰动数据，比如基因编辑，去敲除某一个转录因子，看看靶点的表达情况

蛋白质相互作用网络构建

在构建 PPI 网络时，主要想回答两种不同的问题。

- ❑ 二元相互作用图谱 (Binary Interaction Map)
 - 问题：“蛋白质 A 和蛋白质 B，能否在‘理想条件’下，一对一地直接结合？”
 - 网络表示：“轮辐模型” (Spoke Model)。每一条边，都代表一次被验证过的、直接的二元相互作用。
 - 主要检测技术：酵母双杂交系统 (Yeast Two-Hybrid, Y2H)。
- ❑ 共复合物成员图谱 (Co-Complex Membership Map)
 - 问题：“当在细胞里‘定位’蛋白质 A 时，能同时捕获到哪些稳定结合的蛋白质？”
 - 网络表示：“矩阵模型”或“团(Clique)模型”。一个被捕获到的复合物，其所有成员之间，都可能被画上边，表示它们是“同一个俱乐部的成员”。
 - 主要检测技术：亲和纯化-质谱联用 (Affinity Purification-Mass Spectrometry, AP-MS)。
- ❑ 这两种方法是互补的，它们从不同角度揭示了蛋白质的“社交”行为。

目前的问题：
实验数据充满噪声且不完整

数据库：STRING 整合了实验和预测的数据

STRING 整合数据的打分方式：
首先为每个渠道单独打分，然后采用贝叶斯整合，最终得到一个置信度总分。

图聚类：

- ❑ 输入：一个图（Graph），包含节点（Nodes）和边（Edges）。
- ❑ 目标：将图划分为若干个子图（Clusters/Communities）。
- ❑ 特征：
 - 簇内稠密：同一个簇内的节点之间连接紧密。
 - 簇间稀疏：不同簇之间的节点连接较少。
- ❑ 应用场景：
 - 生物信息学（蛋白质相互作用网络分析）。
 - 社交网络分析（发现朋友圈）。
 - 推荐系统。

经典的图聚类算法：

- ❑ MCL 是一种经典的基于随机游走的算法。
- ❑ MCL 的核心思想基于图上的随机游走：
 - 信息流从图中随机从一个节点出发。
 - 如果这个节点处在一个紧密的簇（Cluster）中，那么该信息很有可能在簇内反复跳转。
 - 这个信息通过那几条稀疏的边跳出该簇的概率相对较低。
- ❑ 结论：如果在图上进行足够长时间的随机游走，流（Flow）倾向于被“困”在稠密的区域内。MCL 就是通过模拟这种流的分布来发现聚类。

算法核心步骤（考试）：

- ❑ 扩展（Expansion）
 - 模拟随机游走的扩散过程。
 - 使流从当前节点流向更远的邻居。
- ❑ 膨胀（Inflation）
 - 模拟竞争过程（这是聚类的关键）。
 - 增强强的连接，削弱弱的连接（强者愈强，弱者愈弱）。

算法流程（考试）：

预处理

邻接矩阵 (Adjacency Matrix): A


□ **第一步：**添加自环 (Self-Loops):

- 让矩阵对角线元素为 1。
- 目的：确保在该节点不仅能流向邻居，也有**概率停留在自身**（这对数学收敛很重要）。

□ **第二步：**归一化 (Normalization):

- 将矩阵按列归一化，使其成为**随机矩阵 M** ，即每一列的和为 1。
- 此时矩阵代表一阶转移概率。

A. 一个简单的网络及其邻接矩阵



B. 第一步：增添自连接

$$\begin{pmatrix} 1 & 1 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 \end{pmatrix}$$

C. 第二步：矩阵归一化（列）

$$\begin{pmatrix} 0.25 & 0.33 & 0.5 & 0.33 \\ 0.25 & 0.33 & 0 & 0.33 \\ 0.25 & 0 & 0.5 & 0 \\ 0.25 & 0.33 & 0 & 0.33 \end{pmatrix}$$

37

扩展

□ **第三步：**计算矩阵的乘方（通常是平方）。

$$M_{new} = M \times M$$

□ 物理意义：

- 矩阵乘法对应于计算两步（或多步）可达的概率。
- 它让流从节点扩散开来，观察更广阔的图结构。
- 这会使得概率分布变得更加平滑（均匀化）。

D. 第三步：矩阵扩展（矩阵平方）

$$\begin{pmatrix} 0.25 & 0.2175 & 0.25 & 0.2175 \\ 0.25 & 0.2175 & 0.125 & 0.2175 \\ 0.125 & 0.0825 & 0.25 & 0.0825 \\ 0.25 & 0.2175 & 0.125 & 0.2175 \end{pmatrix}$$

膨胀

□ **第四步：**对矩阵中的每个元素进行幂运算（参数 r ），然后重新归一化

$$M_{ij} = (M_{ij})^r$$

□ 物理意义：

- 这是 MCL 引入的非线性操作。
- 如果 $r > 1$ （例如 $r=2$ ）：
 - ✓ 大概率（如 0.9）平方后仍较大（0.81）。
 - ✓ 小概率（如 0.1）平方后变得极小（0.01）。
- 结果：消除了簇与簇之间微弱的连接，强化了簇内的强连接。

E. 第四步：矩阵膨胀（先对矩阵元素平方，再对矩阵每列进行归一化）

$$\begin{pmatrix} 0.0625 & 0.0473 & 0.0625 & 0.0473 \\ 0.0625 & 0.0473 & 0.0156 & 0.0473 \\ 0.0156 & 0.0068 & 0.0625 & 0.0068 \\ 0.0625 & 0.0473 & 0.0156 & 0.0473 \end{pmatrix} \quad \begin{pmatrix} 0.3077 & 0.3182 & 0.4 & 0.3182 \\ 0.3077 & 0.3182 & 0.1 & 0.3182 \\ 0.0769 & 0.0458 & 0.4 & 0.0458 \\ 0.3077 & 0.3182 & 0.1 & 0.3182 \end{pmatrix}$$

39

迭代与收敛

□ 重复 扩展 → 膨胀 的过程。

□ 收敛状态：

- 最终矩阵会变成一个**双重幂等矩阵**。
- 矩阵变得非常稀疏，大部分元素为 0。
- 每一列通常只剩下一个或极少数非零值。

□ 提取结果：

- 根据收敛矩阵的非零元素结构，直接读出聚类结果。

F. 重复第三、四步

G. 最终收敛的矩阵

$$\begin{pmatrix} 1 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 \end{pmatrix}$$

总的来说，就是：

- 输入邻接矩阵，并且加自环
- 对矩阵进行列归一化
- 矩阵乘方—— expansion 拓展
- 对矩阵的每个元素进行幂运算——inflation 膨胀
- 重新归一化
- 重复 3-5 步，直到收敛

上图得到的 G，发现 ABD 是一类，C 是另外一类

□ 优点

- 无需指定簇的数量：不像 K-Means 需要预设 K，MCL 会自动决定簇的数量。
- 鲁棒性：对图中的噪声和边的权重变化具有较好的鲁棒性。
- 可扩展性：由于矩阵在膨胀后变得稀疏，通过稀疏矩阵运算可以加速。

□ 缺点

- 重叠问题：基础 MCL 产生的是**非重叠聚类**（Hard Clustering），节点只能属于一个簇。
- 大图效率：对于数百万节点的图，矩阵乘法即便优化过依然昂贵。
- 分裂敏感：如果图的直径很大，有时会过度分割长链状结构。

如果想直接基于 PPI 网络，对节点进行功能活性打分，可以采用随机游走算法：

重启随机游走：

目标：利用已知功能的蛋白（Seeds），通过网络拓扑结构，推断未知蛋白的功能。

重启（Restart）：信息流传达每走一步，都有一定概率 r （例如 0.7）被“瞬移”回起点（种子节点）。

优势：保证了游走既能探索邻居，又不会离种子节点太远。兼顾了全局拓扑结构和局部邻域信息。

重启随机游走 (RWR)

$$\mathbf{p}_{t+1} = (1 - r)\mathbf{W}\mathbf{p}_t + r\mathbf{p}_0$$

- $\mathbf{p}_{t+1}$ ：下一步所有节点的得分向量。
- $\mathbf{W}$ ：列归一化的邻接矩阵（转移矩阵，决定了怎么走）。
- $\mathbf{p}_0$ ：初始种子向量（例如只有已知 GO 功能的蛋白的位置有值）。
- r ：重启概率 (Restart Probability)。
 - ✓ r 越大：游走越局限，只看近邻。
 - ✓ r 越小：游走越发散，容易跑远。

R 一般取 0.7

输入：PPI 网络 + 功能种子列表（例如 GO）。

过程：通过 $r=0.7$ 的重启随机游走，让功能信号在网络上“可控扩散”。

输出：全网节点的亲疏程度打分。


价值：以低成本计算预测高成本实验的方向。

第八章 生物网络可视化（自主学习部分，省略）

了解 R 语言的画图系统，以及 ggplot2 的使用方法即可



R Graphics

- base
 - low level graphics system
 - paper and pencil without **eraser**
 - authored by R Core Team
- grid
 - low level graphics system
 - produces graphical objects which can be edited
 - allow arbitrary modifications of plots produced by *lattice* and *ggplot2*
 - authored by Paul Murrell



Basic elements in ggplot2 visualization

- data
- geom
 - aesthetics: describe visual characteristics
 - scales: for each aesthetic, describe how visual characteristic is converted to display values
- coordinate system
 - most geoms use default, cartesian



Ggplot2 画图的例子可以看：

<https://github.com/Hinna0818/Bioinfo->

[SMU/blob/main/Grade4/computational biology/ggplot2-test.R](https://github.com/Hinna0818/Bioinfo-SMU/blob/main/Grade4/computational%20biology/ggplot2-test.R)

第九章 系统生物学建模

模型的分类：


□ 1. 对现实的描述：定性 vs. 定量

- ✓ 定性模型：关注系统的**逻辑结构**和可能达到的**状态**，而不关心具体的分子浓度和反应速率。它回答“能不能”的问题。比如：布尔网络
- ✓ 定量模型：精确描述系统中各组分的**浓度**如何随**时间**变化。它回答“有多少”和“有多快”的问题。比如：常微分方程

□ 2. 对随机性的处理：确定性 vs. 随机性

- ✓ 确定性模型：假设系统是宏观的、行为是平滑可预测的。在完全相同的初始条件下，每次模拟的结果都**完全相同**。
- ✓ 随机性模型：认为化学反应在分子层面是**随机事件**。在完全相同的初始条件下，每次模拟的结果都不尽相同，会有一个概率分布。

生物系统建模的基本过程



布尔模型（考试）：描述离散系统状态和相互作用

□ 核心假设：细胞中的每个关键组分（基因、蛋白质），其状态都可以被简化为两个互斥的、离散的水平：


- ✓ ON (1)：代表基因**高表达**、蛋白质**有活性**或**浓度高于**某个阈值。
- ✓ OFF (0)：代表基因**不表达**、蛋白质**无活性**或**浓度低于**某个阈值。

AND 门：转录因子复合体

计算机概念中的“逻辑门”：

□ AND 门

- ✓ 生物学场景：转录因子复合体。一个基因的表达，需要**多个转录因子同时结合**到它的启动子上。
- ✓ 例子：基因C的表达，需要转录因子A和转录因子B都处于激活状态(1)。
- ✓ 逻辑规则： $C(t+1) = A(t) \text{ AND } B(t)$



$$C^* = A \text{ AND } B$$


A(t)	B(t)	C(t+1)
0	0	0
1	0	0
0	1	0
1	1	1

14

OR 门：功能冗余或者多信号整合

□ OR 门

- ✓ 生物学场景：功能冗余或多信号整合。一个下游效应蛋白，可以被**任一上游信号**通路激活。
- ✓ 例子：蛋白C的激活，只需要**激酶A或激酶B**中任意一个处于激活状态(1)即可。
- ✓ 逻辑规则： $C(t+1) = A(t) \text{ OR } B(t)$



$$C^* = A \text{ OR } B$$


NOT 门：转录抑制

一个完整的布尔网络模型包含三个核心组件：

- ❑ 节点 (Nodes):
 - ✓ 代表系统中的关键组分，如基因、蛋白质。
- ❑ 状态 (States):
 - ✓ 每个节点在任意时刻，都处于 ON (1) 或 OFF (0) 两种状态之一。
 - ✓ 整个网络在某一时刻的**系统状态**，由所有节点状态构成的向量来定义。例如，一个 3 节点的网络，其系统状态可以是 (1, 0, 0)。
- ❑ 更新规则 (Update Rules):
 - ✓ 对**每一个节点**，都必须定义一个逻辑函数（由 AND, OR, NOT 组合而成）。
 - ✓ 这个规则明确了该节点的**下一时刻状态**，是如何由其上游节点的**当前状态**决定的。

一个简单的三节点负反馈回路

- ❑ 假设有一个包含三个基因 A, B, C 的微型基因回路。
- ❑ 调控逻辑：
 - ✓ 基因 A 的产物，会**激活**基因 B 的表达。
 - ✓ 基因 B 的产物，会**激活**基因 C 的表达。
 - ✓ 基因 C 的产物，是一个**转录抑制因子**，它会**抑制**基因 A 的表达。
- ❑ 这是一个典型的**延迟负反馈回路**。



问题：

这个系统最终会表现出什么样的长期行为？它会稳定在某个状态，还是会不停地变化？

$$A_{\text{next}} = \text{NOT } C$$

$$B_{\text{next}} = A$$

$$C_{\text{next}} = B$$

20

结果作为 next，写在左边，右边是导致这个结果的条件

问题答案：这个系统最终会形成一个循环。具体的做法：

假设 $t=0$ 时刻 A 被激活，即**系统状态** $S(0) = (1, 0, 0)$ 。

- ✓ 计算下一个状态 $S(1)$ ：
- ✓ 查阅我们的真值表，或者直接应用规则：
 - ✓ $A(1) = \text{NOT } C(0) = \text{NOT } 0 = 1$
 - ✓ $B(1) = A(0) = 1$
 - ✓ $C(1) = B(0) = 0$

系统状态 $S(1) = (1, 1, 0)$

继续计算下去，发现是一个循环：

- $S(0) = (1, 0, 0)$
- $S(1) = (1, 1, 0)$
- $S(2) = (1, 1, 1)$
- $S(3) = (0, 1, 1)$
- $S(4) = (0, 0, 1)$ ($A=\text{NOT } 1=0, B=0, C=1$)
- $S(5) = (0, 0, 0)$ ($A=\text{NOT } 1=0, B=0, C=0$)
- $S(6) = (1, 0, 0)$ ($A=\text{NOT } 0=1, B=0, C=0$)

对于这个模型，无论从 8 个可能状态中的哪一个开始，最终的命运都是一样的：进入并永远地循环。

Attractor: 系统的最终归宿

- 定义：吸引子是状态空间中的一个子集，一旦系统的轨迹进入这个子集，就再也无法离开。

➤ 它是系统长期行为 (long-term behavior) 的体现。

- 吸引域 (Basin of Attraction): 指的是所有最终会演化到同一个吸引子的初始状态的集合。

分析布尔网络的核心任务，就是找到它所有的吸引子。

吸引子的类别：

稳态吸引子，比如 $S(t+1)=S(t)$ 举例：细胞分化状态

极限环吸引子（比如上面那个例子） 举例：细胞周期

布尔网络的优缺点：

优点：

- 无需动力学参数

- 这是它最大的优点。我们不需要知道精确的反应速率、结合常数等。这些参数在实验上往往极难获得。
- 我们只需要关于网络拓扑和调控逻辑（激活/抑制）的定性知识，而这些相对容易从文献或功能实验中获得。

- 可扩展性好，适合大规模网络

- 由于其计算的简单性，布尔网络可以用来分析包含成百上千个节点的复杂网络，例如全细胞规模的基因调控网络。
- 这对于定量模型（如 ODE）来说，几乎是不可能完成的任务，因为参数数量会爆炸式增长（“维度灾难”）。

缺点:

❑ 过于简化, 丢失定量信息

- “开/关”的二元假设, 忽略了分子浓度的连续变化。
- 它无法区分“微弱的激活”和“强烈的激活”, 也无法描述剂量效应曲线。在某些情况下, 这些定量的细节是至关重要的。

❑ 离散且同步的时间模型不真实

- 假设所有反应都在一个统一的、离散的时间步长内完成, 这与真实的、异步的、发生在不同时间尺度上的生化反应不符。
- 例如, 转录和翻译可能需要几十分钟, 而磷酸化可能在几秒钟内完成。布尔网络无法体现这种差异。

ODE 微分方程模型:

- ❑ 状态是连续的 (浓度)。
- ❑ 它能精确描述系统动态过程的每一个细节。
- ❑ 通过 ODE, 可以探索这些关于速率、时间和浓度的精细问题。

核心思想:

- ❑ $d[X]/dt = \text{总生产速率} - \text{总降解速率}$
- $[X]$: 代表我们关心的分子 (如蛋白质 X) 的浓度。
- $d[X]/dt$: 代表该分子浓度的瞬时变化率。
- 生产速率 (Production): 所有导致 X 浓度增加的过程的总和。
- 降解速率 (Degradation): 所有导致 X 浓度减少的过程的总和。

零阶过程 (Zeroth-Order Process)

- ❑ 描述: 一个过程的速率是恒定的, 与反应物浓度无关。
- ❑ 数学形式: 速率 = k
- ❑ 生物学应用: 恒定速率生产 (Constitutive Production)
 - 场景: 一个基因由一个组成型启动子驱动, 不受任何调控, 以一个基本恒定的速率进行转录和翻译。
 - ODE 贡献项: $dX/dt = k_{\text{prod}}$
 - k_{prod} : 零阶生产速率常数。

一阶过程 (First-Order Process)

- ❑ 描述: 一个过程的速率, 与单个反应物的浓度成正比。
- ❑ 数学形式: 速率 = $k * [X]$
- ❑ 生物学应用: 一阶降解 (First-Order Degradation)
 - 场景: 蛋白质 X 被细胞内的降解机器 (如蛋白酶体) 随机地识别和清除。浓度越高, 单位时间内被清除的分子数就越多。

- ODE 贡献项: $\frac{dX}{dt} = \text{xxxxxx} - k_{deg} * [X]$
- k_{deg} : 一阶降解速率常数。它与蛋白质的半衰期 (half-life) 直接相关。

质量作用定律

- ❑ 核心思想: 化学反应的速率, 正比于反应物浓度的乘积。
- ❑ 直观理解: 在一个空间里, 反应物 A 和 B 的分子都在随机运动。
 - A 的浓度越高, B 分子撞上 A 分子的概率就越大。
 - B 的浓度越高, A 分子撞上 B 分子的概率也越大。
 - 因此, A 和 B 相遇并发生反应的速率, 自然就正比于两者浓度的乘积 $[A] * [B]$ 。
- ❑ 适用范围: 适用于描述基础的、非催化的化学反应, 如:
 - 二聚化: $A + A \rightarrow A_2$
 - 异源二聚化: $A + B \rightarrow AB$
 - 解离: $AB \rightarrow A + B$

质量作用定律

- ❑ 正向反应 (结合): $A + B \rightarrow C$
 - 这是一个双分子反应。
 - 根据质量作用定律, 其速率为 $k_{on} * [A] * [B]$ 。
✓ k_{on} : 结合速率常数。
- ❑ 逆向反应 (解离): $C \rightarrow A + B$
 - 这是一个单分子反应。
 - 根据质量作用定律 (此时退化为一阶过程), 其速率为 $k_{off} * [C]$ 。
✓ k_{off} : 解离速率常数。
- ❑ 为 C 写出完整的 ODE 方程:
 - $\frac{d[C]}{dt} = (\text{C 的生产速率}) - (\text{C 的降解速率})$
 - $\frac{d[C]}{dt} = k_{on} * [A] * [B] - k_{off} * [C]$

质量作用定律的局限: 现实并非无限线性

- 一个酶催化反应: 酶(E) + 底物(S) $\rightarrow$ 酶(E) + 产物(P)
- 如果用质量作用定律来描述: 速率 = $k * [S]$ 。这意味着, 底物浓度越高, 反应速率就无限地、线性地增长。
- 现实是: 酶的数量是**有限**的。当底物浓度高到一定程度, 所有的酶分子都在起作用, 达到了它们处理能力的极限。此时, 即使再增加底物, 反应速率也**不会再显著增加**。
- 这种现象, 称之为“**饱和**”(Saturation)。
- 需要一个新的数学“**标准件**”来描述这种**饱和曲线**。

米氏动力学:

□ Michaelis-Menten Kinetics: 描述酶催化反应

- 20 世纪初, 生物化学家 Leonor Michaelis 和 Maud Menten 研究蔗糖酶。他们提出了一个两步模型来解释“饱和”现象:
 - ✓ 1. 第一步 (快速可逆): 酶(E)和底物(S)快速结合, 形成一个**酶-底物复合物(ES)**。 $E + S \rightleftharpoons ES$
 - ✓ 2. 第二步 (慢速不可逆): ES 复合物缓慢地催化反应, 释放出产物(P)和自由的酶(E)。 $ES \rightarrow E + P$
 - ✓ 核心: 反应的瓶颈在于**第二步**。反应速率, 取决于有多少酶结合在了 ES 复合物里。

米氏动力学:

□ 方程与曲线

$V = (V_{\max} * [S]) / (K_m + [S])$ (这一部分跟 CADD 类似)

- V: 反应速率 (Velocity)。
- [S]: 底物浓度 (Substrate Concentration)。
- $V_{\max}$: **最大反应速率**。当酶完全被底物饱和时的速率。它正比于**总的酶浓度**。
- K_m : **米氏常数**。等于反应速率达到一半 $V_{\max}$ 时所需的**底物浓度**。它反映了酶与底物的**亲和力** (K_m 越小, 亲和力越高)。

米氏动力学:

□ 方程的极限行为

□ 当底物浓度很低时 ($[S] \ll K_m$):

- 分母中的 [S] 可以忽略不计, $K_m + [S] \approx K_m$ 。
- 方程近似为: $V \approx (V_{\max}/K_m) * [S]$
- 行为: 速率与底物浓度成**线性关系** (一阶过程)。这与质量作用定律一致。

□ 当底物浓度很高时 ($[S] \gg K_m$):

- 分母中的 K_m 可以忽略不计, $K_m + [S] \approx [S]$ 。
- 方程近似为: $V \approx (V_{\max} * [S]) / [S] = V_{\max}$
- 行为: 速率达到**恒定的最大值 $V_{\max}$** (零阶过程), 与底物浓度无关。这就是饱和。

- ✓ 很多情况下, 一个启动子需要**多个**转录因子分子结合才能有效激活。
- ✓ 并且, 第一个 TF 分子的结合, 可能会让 DNA 构象发生变化, 使得**第二个 TF 分子更容易**结合, 反之亦然。
- ✓ 这种“一呼百应”的效果, 会导致基因的响应曲线, 比米氏方程的 S 型曲线**更陡峭**, 更像一个“**数字开关**” (digital switch)。

希尔函数：

The Hill Function: 描述**协同性**的现象学模型

- ❑ **历史：** 源于生理学家 Archibald Hill 在 20 世纪初对血红蛋白 (Hemoglobin) 结合氧气的研究。他发现血红蛋白的氧结合曲线是 **S 形** 的，而非双曲线，揭示了四个亚基间的协同效应。
- ❑ **本质：** 希尔函数可以看作是**米氏方程**的一个推广。它通过引入一个额外的参数——**希尔系数 n**——来描述系统的协同性。
- ❑ 它是一个**现象学模型 (phenomenological model)**：它本身没有详细描述协同结合的每一步微观过程，但它能非常好地**拟合和描述**最终观察到的 S 形响应曲线。

希尔函数：激活型

$$V = (V_{\max} * [A]^n) / (K^n + [A]^n)$$

- V: 反应速率 (如基因表达速率)。
- [A]: 激活剂的浓度 (Activator)。
- $V_{\max}$: 最大速率。
- K: 激活系数 (Activation Coefficient)。速率达到一半 $V_{\max}$ 时所需的**激活剂浓度**。
- n: 希尔系数 (Hill Coefficient)。
- 描述协同性的强度。
 - ✓ $n = 1$: **无协同性**。此时希尔函数退化为米氏方程。
 - ✓ $n > 1$: **正协同性**。n 越大，曲线越陡峭，开关特性越强 (Ultrasensitive)。
 - ✓ $n < 1$: **负协同性** (较少见)。

希尔函数：抑制型

$$V = V_{\max} * (K^n) / (K^n + [I]^n) \text{----只是把 A 换成了 I}$$

- ❑ [I]: 抑制剂的浓度 (Inhibitor)。
- ❑ K: 抑制系数 (Inhibition Coefficient)。当速率下降到一半 $V_{\max}$ 时所需的**抑制剂浓度**。
- ❑ n: **希尔系数**，同样描述协同性。
- ❑ 行为：
 - 当 $[I] = 0$ 时, $V = V_{\max}$ (无抑制)。
 - 当 $[I] = K$ 时, $V = V_{\max} / 2$ (半抑制)。
 - 当 $[I]$ 很大时, V 趋近于 0 (完全抑制)。

ODE 定量模型案例（考试）

单个基因的自激活正反馈通路

基因 X 能够以一个较低的基础速率进行表达。

基因 X 表达产生的蛋白质 X，本身又是一个转录因子，它可以结合到自身的启动子上，强烈地激活自身的表达。

蛋白质 X 以一阶速率被降解。

任务：为蛋白质 X 的浓度 $[X]$ 写出完整的 ODE 方程。

一步步构建 ODE（考试）

$d[X]/dt = (\text{总生产}) - (\text{总降解})$

□ 1. 总生产速率 = ?

- 它由两部分构成：基础表达 + 自激活表达
- 基础表达是恒定的 $\rightarrow$ 零阶过程 $\rightarrow k_{\text{basal}}$
- 自激活是协同的 $\rightarrow$ 激活型希尔函数 $\rightarrow (V_{\text{max}} * [X]^n) / (K^n + [X]^n)$
- 总生产 = $k_{\text{basal}} + (V_{\text{max}} * [X]^n) / (K^n + [X]^n)$

□ 2. 总降解速率 = ?

- 蛋白质被线性降解 $\rightarrow$ 一阶过程 $\rightarrow k_{\text{deg}} * [X]$

□ 3. 组合起来：最终的 ODE 方程

- $d[X]/dt = k_{\text{basal}} + (V_{\text{max}} * [X]^n / (K^n + [X]^n)) - k_{\text{deg}} * [X]$

第十章 参数估计与模型验证（自主学习）

如何衡量拟合效果：

- t_i, y_i ：代表第 i 个实验数据点（在 t_i 时刻，测得的值是 y_i ）。
- $y_{\text{model}}(t_i)$ ：代表我们的模型，在给定一组参数后，于 t_i 时刻预测的值。
- 残差 (Residual)： $y_i - y_{\text{model}}(t_i)$ ，即在某个时间点，真实值与预测值的差距。
- 平方 (Squared)：
 - 可以消除正负号的影响（我们只关心差距的大小，不关心方向）。
 - 可以“惩罚”那些偏差大的点，使得优化算法更倾向于修正大的错误。
 - 求和 (Sum)：将所有数据点的误差加起来，得到一个总的“成本”。

我们假设，任何一次实验测量值 y_{data} ，都由两部分构成：

$y_{\text{data}}(t_i) = y_{\text{model}}(t_i, \theta) + \epsilon_i$

- ✓ $y_{\text{model}}(t_i, \theta)$ ：是模型描述的、无噪音的“真实值”
- ✓ ϵ_i ：是一个随机的“测量误差”。

关键假设：误差服从正态分布

我们进一步假设，这个测量误差 ϵ_i 是从一个均值为 0，方差为 σ^2 的正态分布（高斯分布）中抽取的样本。

$\epsilon_i \sim N(0, \sigma^2)$

这意味着：

- 测量结果在“真值”附近出现的概率最大。
- 出现巨大偏差（很大的正或负误差）的概率极小。
- 这在大量独立随机因素（如移液误差、仪器波动）共同作用下，是一个非常合理的假设。

这一部份和大三上的生物统计学回归那一部份是一样的

参数估计：点估计和最大似然估计

最大似然估计：给定某组参数，假设服从某个分布，使其观测的概率最大

如果不同数据点的噪音水平不同：

❑ 解决方案：加权最小二乘（WLS）

- 思想：赋予更可信的数据点（低方差）更大的话语权。
- 目标函数： $J(\theta) = \sum w_i * [y_{data}(t_i) - y_{model}(t_i, \theta)]^2$
- 权重 (Weight): $w_i = 1 / \sigma_i^2$ （权重与方差成反比）

最大似然估计的步骤：

❑ 1. 第一步：为你的数据选择一个合理的统计分布（噪音模型）。

- 连续浓度？→ 正态分布（Normal）
- 单分子计次？→ 泊松分布（Poisson）
- 成功/失败事件？→ 二项分布（Binomial）

❑ 2. 第二步：根据所选分布，写出似然函数 $L(\theta | \text{Data})$ 。

❑ 3. 第三步：寻找参数 θ ，最大化 $L(\theta | \text{Data})$ 或 $\log L(\theta | \text{Data})$ 。

优化算法：局部优化和全局优化

局部优化：梯度下降法、牛顿法、高斯-牛顿法、LM 算法

全局优化：模拟退火、遗传算法、粒子群优化、多起点策略

贝叶斯推断—引入概率，置信区间，不确定性

马尔可夫链蒙特卡洛

模型的可辨识性分析